GOVERNO DO ESTADO DO RIO DE JANEIRO SECRETARIA DE ESTADO DE CIÊNCIA E TECNOLOGIA FUNDAÇÃO DE APOIO À ESCOLA TÉCNICA CURSO SUPERIOR DE TECNOLOGIA EM ANÁLISE E DESENVOLVIMENTO DE SISTEMAS

Desenvolvimento de ferramenta de chat com IA integrada - IAtendente

CAIO LINCOLN RODRIGUES DO SACRAMENTO

YVES DA SILVA SOUZA DE MATTOS

Rio de janeiro

Novembro 2024

Desenvolvimento de ferramenta de chat com IA integrada - IAtendente

CAIO LINCOLN RODRIGUES DO SACRAMENTO

YVES DA SILVA SOUZA DE MATTOS

Trabalho de conclusão de curso apresentado como requisito parcial para a obtenção do título de Tecnólogo em Análise e Desenvolvimento de Sistemas pela Faculdade de Educação Tecnológica do Estado do Rio de Janeiro.

Orientador: Prof. Me. Márcio Belo Rodrigues da Silva.

Rio de janeiro

Novembro 2024

RESUMO

Este trabalho visa modelar e implementar um sistema de Help Desk facilmente plugável em sistemas web, que seja com ênfase no atendimento em tempo real (chat). O projeto busca incorporar ferramentas de *Machine Learning* para otimizar o tempo de atendimento, aumentando a eficiência no processo e aprimorando a produtividade do setor de suporte de uma empresa. A integração dessas tecnologias tem como objetivo automatizar respostas e agilizar soluções para questões comuns, melhorando a experiência do cliente e reduzindo a demanda de interação humana para problemas recorrentes.

PALAVRAS-CHAVE: Inteligência Artificial; Chat de atendimento; Suporte; Machine Learning

ABSTRACT

This work aims to model and prototype a Help Desk system with a focus on real-time support (chat). The project seeks to integrate Machine Learning tools to streamline response time, enhancing the efficiency and productivity of a company's support sector. By automating answers and accelerating solutions for common issues, the integration of these technologies aims to improve the customer experience while reducing the need for human interaction on repetitive problems.

KEYWORDS: Artificial Intelligence; Support Chat; Help Desk; Machine Learning

Sumário

1. INTRODUÇÃO 7

2. OBJETIVO GERAL 9

3. OBJETIVOS ESPECÍFICOS 9

4. FUNDAMENTAÇÃO TEÓRICA 10

4.1. ANÁLISE TOMTICKET 12

4.2. ANÁLISE DOS MODELOS DE APRENDIZAGEM 19

4.2.1. BERT, *DISTILBERT*: *BERT* (*BIDIRECTIONAL ENCODER REPRESENTATIONS FROM TRANSFORMERS*) 20

4.2.2. JACCARD 22

4.2.3. PARAPHRASE-MINILM 24

5. DIAGRAMA DE CASOS DE USO 27

6. DIAGRAMA DE CLASSES 38

7. DICIONÁRIO DE DADOS 39

8. DIAGRAMA ARQUITETURAL 41

9. FLUXO DE TELAS 42

9.1. MODAL FECHADO 42

9.2. FORMULÁRIO DE IDENTIFICAÇÃO 42

9.3. MENSAGEM INICIAL DO CHAT 43

9.4. MENSAGEM ENVIADA PELO CLIENTE 43

9.5. LOGIN DO SUPORTE 44

9.6. TELA INICIAL DO SISTEMA DO SUPORTE 44

9.7. INTERAÇÃO ENTRE CLIENTE E SUPORTE 45

9.8. NOTIFICAÇÃO DE ATENDIMENTO NA TELA DO SUPORTE 46

9.9. CONVERSA COM O CLIENTE 46

9.10. ABERTURA DE TICKET 47

10. CONCLUSÃO.....49
11. CONSIDERAÇÕES FINAIS 49
12. ENCAMINHAMENTOS FUTUROS 49
13. REFERÊNCIAS.....50

1. INTRODUÇÃO

Atualmente, o atendimento ao cliente tornou-se uma peça fundamental para garantir a competitividade e a sustentabilidade de empresas que interagem diretamente com o público. Esse fator é ainda mais essencial em organizações que oferecem seus serviços em ambientes virtuais, onde a qualidade do atendimento pode determinar diretamente o nível de satisfação e a fidelização de clientes. Segundo um estudo publicado pelo portal eNotas [1], a disponibilização de um suporte especializado contribui significativamente para a retenção de clientes, a maximização do uso de funcionalidades do sistema e a redução da curva de aprendizado necessária para a adaptação a soluções tecnológicas mais complexas.

A automação no atendimento ao cliente, especialmente por meio de tecnologias como *chatbots* e sistemas de bate-papo, tem ganhado destaque como uma eficiente estratégia para melhorar a experiência final do usuário. Conforme apontado por um artigo da PPNTecnologia, a implementação de chatbots e sistemas automatizados permite, entre outras vantagens, a identificação de padrões de comportamento dos consumidores. Isso, por sua vez, facilita a personalização do atendimento e o direcionamento de interações de forma mais assertiva, além de possibilitar uma filtragem mais precisa de dados, fornecendo informações valiosas para a tomada de decisões estratégicas.

Além disso, o uso de técnicas avançadas de Inteligência Artificial (IA), como o Processamento de Linguagem Natural (PLN), tornou possível a criação de robôs de atendimento mais sofisticados, que conseguem interagir com os clientes de maneira natural e eficiente. De acordo com Følstad et al. (2019 apud Schunk, 2020):

> “Ao aliar o processamento de linguagem natural com o uso de inteligência artificial, podemos identificar algumas opções de uso voltadas ao processo de atendimento ao cliente, como, por exemplo, os robôs de atendimento automatizados, também conhecidos como chatbots”.

Esse avanço na tecnologia permite que as empresas otimizem seus processos de atendimento, reduzindo custos operacionais e ampliando sua capacidade de resposta.

Diante desse contexto, é essencial que as tecnologias que baseiam esses serviços de atendimento evoluam constantemente, a fim de proporcionar uma experiência de máxima qualidade ao cliente final. Ferramentas como softwares de help desk, chatbots, plataformas de atendimento via WhatsApp e sistemas de VoIP são amplamente utilizadas para melhorar a eficiência no suporte ao cliente, e com isso, observa-se que uma integração entre essas ferramentas, quando aplicado de forma correta, pode oferecer um atendimento ainda mais preciso. Neste trabalho, propõe-se o desenvolvimento de um sistema de chat plugável integrado com IA, que combina a eficiência dos softwares de *help desk* com a flexibilidade dos chatbots.

Dessa forma, este trabalho visa demonstrar o desenvolvimento de uma ferramenta integrada para atendimento ao cliente, focada em um sistema de chat que utiliza técnicas de *Machine Learning* para otimizar o tempo de resposta e a eficiência do suporte. O objetivo é criar uma solução que responda de forma automatizada a questões comuns, oferecendo um atendimento mais ágil e personalizado, o que resultará em maior satisfação do cliente e redução da necessidade de intervenção humana em interações repetitivas. Assim, espera-se que esta ferramenta contribua para o aprimoramento dos processos de suporte, destacando seu impacto na transformação digital das empresas e na modernização de seus serviços de atendimento.

2. OBJETIVO GERAL

Este trabalho tem como principais objetivos a modelagem, prototipação e desenvolvimento do MVP (Produto Mínimo Viável) de uma ferramenta plugável para gerenciamento de atendimentos. A solução proposta oferece funcionalidades como atendimento em tempo real e autoatendimento inicial, por meio de um chatbot baseado em técnicas de machine learning.

3. OBJETIVOS ESPECÍFICOS

i. Analisar e entender de que maneira ferramentas atuais de suporte de usuários considerados de sucesso atuam no mercado, auxiliam na evolução empresarial e quais lacunas podem ser preenchidas no sistema a ser desenvolvido.

ii. Modelar uma aplicação que auxilie os profissionais de suporte a prestarem um atendimento objetivo, controlado e que possibilite ao cliente uma comunicação unificada e direta com a empresa.

iii. Efetuar a comparação entre modelos de IA, de forma que seja avaliada a que melhor possa atender aos requisitos elencados.

iv. Criar um MVP de uma ferramenta de chat que seja integrável em diversos segmentos, embasado em estudo de caso de um software similar, mas contextualizado em um nicho específico (suporte de sistema ERP para controladoras de pragas).

4. FUNDAMENTAÇÃO TEÓRICA

Dos temas mais discutidos nas empresas, principalmente nas que fornecem serviços, é a qualidade do atendimento ao cliente, exemplificado em questões como retorno de solicitações, padronização de respostas, nível de atendimento e principalmente, ganho na eficácia da resolução das solicitações. Com base nos estudos feitos no artigo do site Zendesk[3], de maneira equivocada, muitas empresas entendem que o simples fato de alocar pessoas para responder os clientes ou atender às solicitações é o suficiente. Isto, evidentemente, não irá resolver o problema em grande parte dos casos. Em situações mais simplórias, uma abordagem menos técnica será capaz de solucionar, porém, em muitos contatos, as demandas exigirão uma resposta mais formal, mais bem embasada em regras de negócios bem estabelecidas e uma agilidade compatível com a urgência da solicitação.

Entre as formas comuns de atendimento, especificamente em micro e pequenas empresas B2C, pode-se listar o e-mail, ligação, mensagem instantânea (Whatsapp, Telegram, Wechat, afins), e em casos de uma maior necessidade de formalização de atendimento, reuniões via ferramentas como Zoom, Google Meeting, Microsoft Teams, etc. Todas estas ferramentas conseguem atender pontos específicos, porém, as limitações podem ser bastante problemáticas, principalmente a longo prazo.

Em ferramentas de mensagem instantânea, como o nome sugere, destaca-se o benefício da instantaneidade, que é altamente valorizado pelos clientes. No entanto, em muitos casos, esse imediatismo pode ser prejudicial, pois cria uma expectativa de que sempre haverá alguém disponível, o que nem sempre corresponde à realidade. Em relação ao e-mail e aos aplicativos de reunião, os benefícios incluem a formalidade e a humanização do atendimento; porém, o e-mail resulta em uma comunicação mais lenta, e as reuniões tendem a consumir tempo e, muitas vezes, não geram um histórico conciso, dificultando o acompanhamento por meio de métricas.

Conforme mencionado, a empresa que será utilizada como piloto, contratou um sistema com essa finalidade, porém ao decorrer da utilização e homologação do produto, foram identificados alguns pontos que não seriam atendidos. O principal deles, é a volatilidade e imprevisibilidade de funcionalidades. Nesse caso específico, a contratação incluiu um plano que oferecia alguns serviços essenciais, mas que

foram descontinuados após uma atualização na política de serviços da empresa. Com isso, a contratação se tornou onerosa, e o desenvolvimento de um software mais direcionado às necessidades da empresa foi considerado uma prioridade, de modo a permitir que o suporte seja mais eficiente, embora o sistema também possa ser adaptado para atender a outras necessidades similares.

Assim, destacam-se os principais pontos em que o TomTicket não atende às necessidades identificadas:

- Custo de utilização (assinatura) e reajustes recorrentes.
- Alteração nas funcionalidades disponíveis no plano, sem aviso prévio. Com isso, algo que os clientes estão utilizando passa a não fazer mais parte do pacote contratado.
- Falta de integração com ferramentas de IA.

4.1. ANÁLISE TOMTICKET

Antes de explorar a ferramenta, é importante entender o que é o Tomticket. Segundo o próprio site, "TomTicket é um sistema especializado no gerenciamento de chamados de help desk e atendimento online via chat, permitindo que você o integre ao seu site para aprimorar o atendimento ao cliente."

O ponto de partida será a análise das funcionalidades oferecidas pelo TomTicket para atendimento online em seu **plano básico**. Tomando como referência o uso da ferramenta na empresa ***Cygnus Software***, foram listados os principais usos e necessidades. Em relação à necessidade, o fluxo essencial segue o esquema abaixo:

- Cliente entra em contato.
- Envia uma mensagem que será direcionada para o setor/departamento/carteira/suporte disponível.
- Caso não haja disponibilidade de um suporte direto (leia-se, do suporte responsável ou do setor escolhido), será alocado para um atendimento imediato de qualquer suporte disponível, que avaliará a possibilidade do atendimento do chamado, ou o direcionamento para o responsável, quando houver a sua disponibilidade.
- Caso o problema não seja imediatamente resolvido, o atendimento se torna um ticket, que será possível ser acompanhado pelo cliente (todos poderão ser acompanhados, mas esse é especial, pois está em aberto).
- Quando for solucionado, o responsável irá inserir as informações de resolução.
- O sistema notificará o cliente da resolução.

Em relação às funcionalidades do plano básico do TomTicket, temos conforme abaixo:

- **Script para Integração**: Funcionalidade para geração de script da ferramenta para ser integrado ao sistema que irá utilizar.
    - Uma funcionalidade deste tipo é bastante útil para as primeiras etapas para a implementação do help-desk, pois conecta a ferramenta ao software cliente de maneira simples.
- **Personalização de logotipo:** Funcionalidade para personalização de logotipo da funcionalidade.
    - Útil, mas não relevante. Sem valor comercial.
- **Atendimento por Departamento:** Funcionalidade que permite selecionar um departamento específico para atendimento ao chamado.
    - Importante, sendo uma das principais necessidades do nosso cliente, para controle de atendimento.
- **Avaliação do Atendimento:** Funcionalidade que possibilita o cliente avaliar o atendimento.
    - Essencial para gerenciamento de equipe, avaliação de métricas e tomada de decisão interna.
- **Mensagem de Boas-Vindas Personalizada:** Funcionalidade que permite a definição de uma mensagem inicial ao cliente, de forma a agilizar o atendimento.
    - Sem valor comercial para nosso cliente.
- **Histórico de Atendimentos Realizados:** Funcionalidade que possibilita a visualização do histórico de atendimentos realizados.
    - Fundamental para que não haja retrabalho caso o cliente final seja atendido por outro profissional. Além disso, é importante para a empresa fornecedora do serviço manter um SLA adequado e resguardar ambas as partes a respeito da integridade do atendimento.
- **Aviso Sonoro de Novo Atendimento:** Alerta sonoro ao atendente quando houver um novo atendimento.
    - Útil a nível de UX, principalmente em questão de agilização de atendimento, mas não essencial para utilização do cliente.

- **Aviso Sonoro de Nova Mensagem:** Alerta sonoro ao cliente/atendente quando houver um novo atendimento.
    - Útil a nível de UX, principalmente em questão de agilização de atendimento, mas não essencial para utilização do cliente.
- **Notificações Visual de Nova Mensagem:** Notificação ao cliente/atendente de nova mensagem na aba da página.
    - Útil a nível de UX, principalmente em questão de agilização de atendimento, mas não essencial para utilização do cliente.
- **Envio de Mensagem ao Atendimento estar Offline:** Mensagem personalizada caso não haja atendente disponível no momento.
- **Envio de Cópia do Atendimento ao Cliente**: Envio de cópia ao cliente do atendimento, após este ser finalizado.
    - Interessante de ter, mas a nível do nosso cliente, não é essencial

Na imagem abaixo descrevemos o fluxo de atendimento do TomTicket:

Figura 1 – Fluxo de atendimento do TomTicket

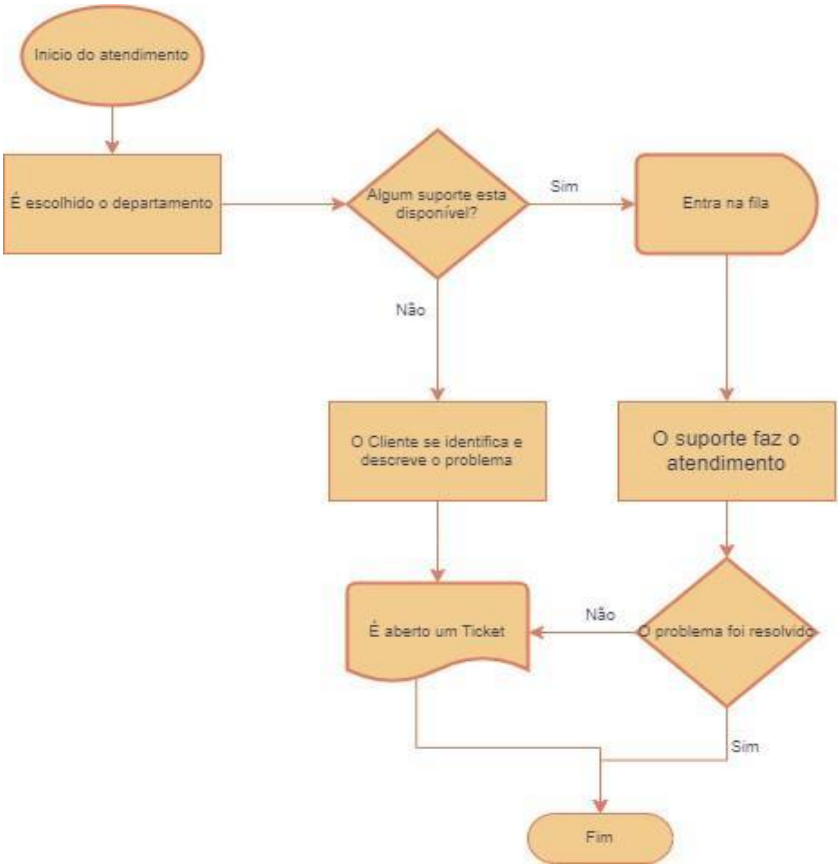

Fonte: De autoria própria.

Já o fluxo de atendimento esperado do IAtendente deve seguir conforme abaixo:

Figura 2 – Fluxo de atendimento projetado para o IAtendente

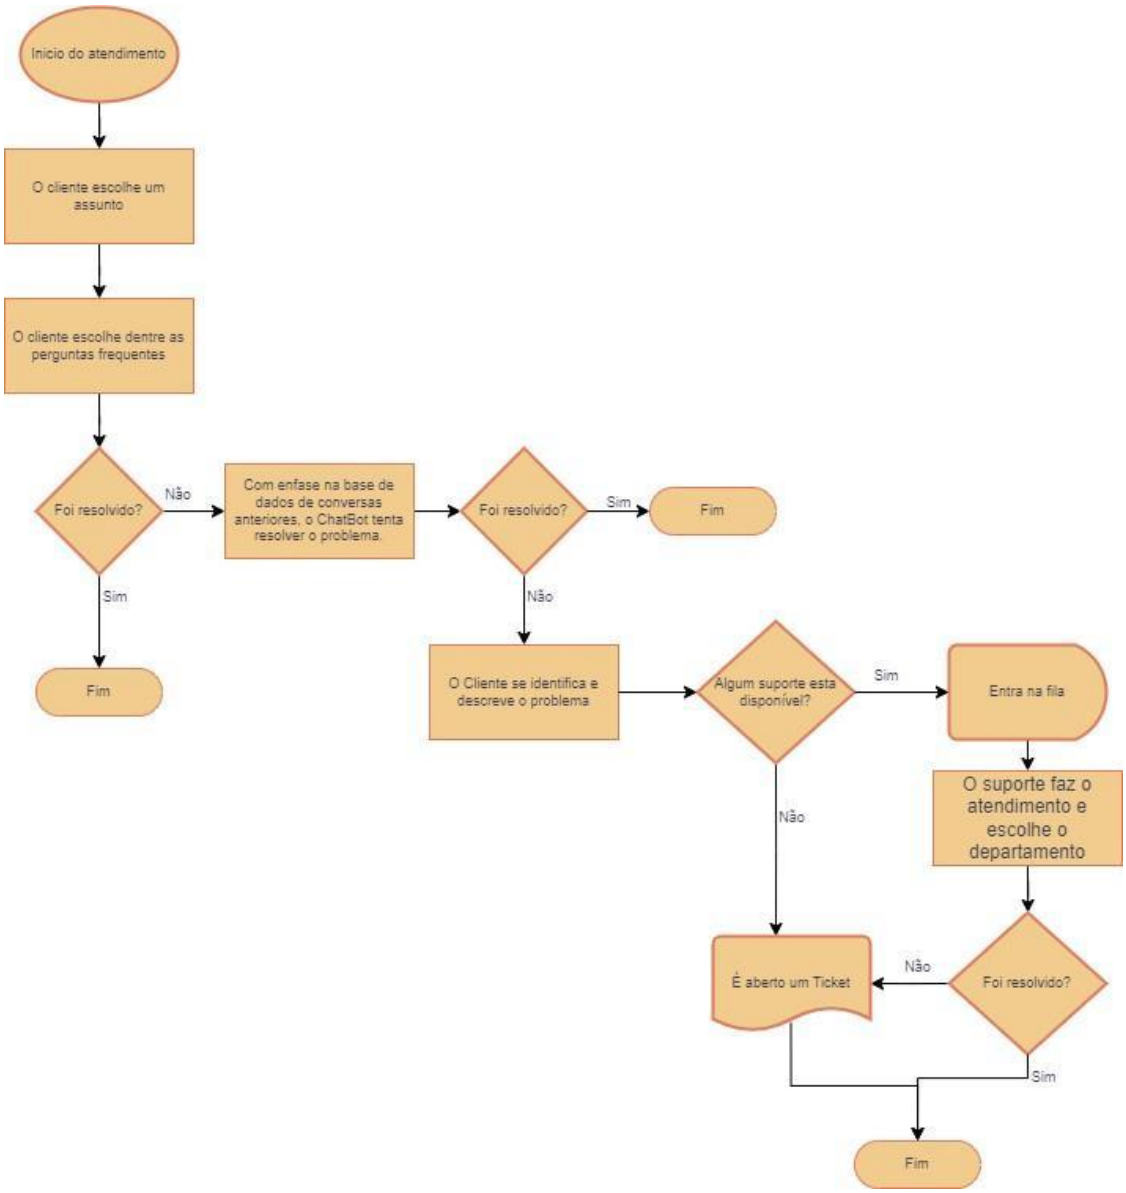

Fonte: De autoria própria.

Com base nas funcionalidades analisadas e priorizando o que realmente atenderia às necessidades do cliente, foi possível especificar de que forma uma nova ferramenta poderá melhorar a experiência do cliente modelo. Dessa forma, as funcionalidades essenciais para um MVP (Produto Mínimo Viável) incluem:

- Atendimento em chat em tempo real.
- Avaliação do Atendimento: Possibilidade de o cliente avaliar o suporte recebido, fornecendo feedback e permitindo a melhoria contínua do serviço.
- Histórico de Atendimentos Realizados: Registro detalhado das interações anteriores, possibilitando consultas futuras e um acompanhamento mais personalizado do atendimento.
- Módulo que reduza a demanda das pessoas responsáveis pela tarefa do atendimento, por exemplo, um pré-atendimento realizado por uma IA, com utilização de *machine learning*.

Além dessas funcionalidades básicas, será necessário implementações adicionais para melhor atender às demandas específicas, tais como:

- Integração simplificada com o sistema cliente: Implementação de uma integração eficiente com o sistema já utilizado pela empresa, assegurando um fluxo de dados contínuo e sem interrupções.
- Crescimento Escalável: Capacidade do sistema de crescer e se ajustar de acordo com o aumento na demanda, sem comprometer o desempenho.
- Solução de Custo Reduzido: Ao investir no desenvolvimento de um sistema próprio, eliminam-se as despesas recorrentes com assinaturas, resultando em uma solução economicamente mais vantajosa a longo prazo.

Esse conjunto de funcionalidades visa garantir que o MVP atenda não apenas às necessidades básicas de atendimento, mas também ofereça uma estrutura flexível e eficiente para o crescimento futuro.

Para exemplificar, a seguir estão os valores das assinaturas atuais do TomTicket (17/04/2024):

Figura 2 – Fluxo de atendimento projetado para o IAtendente

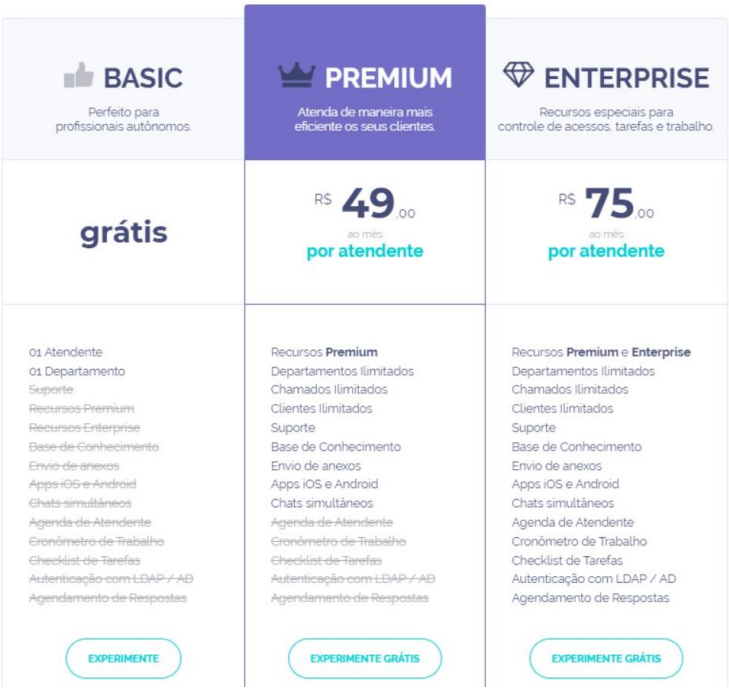

Fonte: Site TomTicket, 2024

Considerando quatro anos de uso no plano “PREMIUM” para 10 suportes o valor seria em torno de R$23.520,00 considerando que não haverá reajuste do valor do plano durante o período. Em comparação direta com o preço, considerando que seriam gastos 3 meses de desenvolvimento, o valor estimado da ferramenta foi de R$17.280,00 (calculando o R$/hora dos desenvolvedores na empresa atual x a quantidade de dias trabalhados em três meses). Sendo assim, no 3º ano de uso a ferramenta já estaria “paga”.

4.2. ANÁLISE DOS MODELOS DE APRENDIZAGEM

Dada a necessidade de implementar uma ferramenta automatizada de atendimento (com algum diferencial voltado para atendimento automatizado) avaliamos algumas formas de realizar esta implementação.

Utilizando a principal linguagem de programação voltada a *machine learning* (*Python*), procuramos as bibliotecas que melhor atendessem às nossas necessidades.

O nosso ponto de partida foi utilizar os modelos de linguagem na plataforma *Hugging Face* [2], que é basicamente um hub de conteúdos voltados ao machine learning e com um amplo conteúdo focado em Processamento de Linguagem Natural (NLP). Utilizamos alguns modelos para testes, como por exemplo o *BERT, Paraphrase-MiniLM, e o Jaccard.* Abaixo detalharemos os resultados de nossos testes e justificaremos a escolha do melhor modelo que nos atendeu.

Os testes foram executados na mesma máquina, de acordo com a configuração abaixo:

Figura 3 – Especificação técnica do computador onde os testes foram realizados

Fonte: De autoria própria.

Figura 4 – Especificação técnica do computador onde os testes foram realizados (*GPU*)

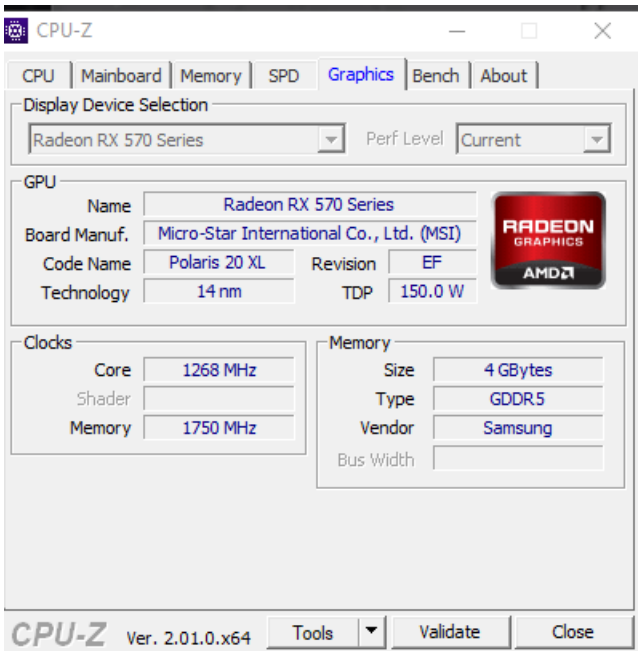

Fonte: De autoria própria.

4.2.1. BERT, DISTILBERT: BERT (BIDIRECTIONAL ENCODER REPRESENTATIONS FROM TRANSFORMERS)

Bert é um avançado modelo de processamento de linguagem natural desenvolvido pela *Google*. Ele aprende a representar palavras e frases em um contexto amplo, capturando significados complexos das palavras. Isso o torna eficaz em várias tarefas de *NLP*, como entender o significado de textos e responder a perguntas. Já o *DistilBERT*, é uma versão mais leve e eficiente do *BERT* criada pela *HuggingFace*. Ele oferece desempenho comparável ao *BERT* original, mas com menos exigência de recursos computacionais, sendo ideal para dispositivos móveis e aplicações web.

Quando utilizamos estes modelos, encontramos principalmente dois pontos de dificuldade, ambos relacionados à performance. O primeiro, foi sobre o tempo de processamento de aprendizagem. O treinamento de um modelo de aprendizagem, como o *BERT*, envolve alimentar o modelo com grandes quantidades de dados para que ele possa aprender padrões e relações entre palavras e frases. Durante o treinamento, o modelo ajusta seus parâmetros internos para minimizar erros em tarefas específicas, como entender o significado de uma frase ou responder a perguntas. Este processo permite que o modelo se torne capaz de realizar tarefas complexas de processamento de linguagem natural com maior precisão. É recomendado pela documentação da *HuggingFace* que o treinamento seja efetuado utilizando uma *GPU Nvidia*, de forma a otimizar o processo. Já o segundo, foi em relação ao tempo de resposta, observamos também uma demora considerável. Cada requisição demorava cerca de 15-20 segundos, um tempo relativamente alto para uma ferramenta com este propósito.

Para fins de testes, utilizamos uma base com cerca de 150 pares de perguntas e respostas, de forma a “ensinar” os modelos fornecerem as respostas às suas perguntas. Nos 3 modelos/submodelos do *BERT* (*DistilBERT* e *RoBERTa*, que é uma versão desenvolvida pelo Facebook) que testamos, o tempo de treinamento foi entre 40-50 minutos.

Figura 5 – Exemplo utilizando o *Bert*

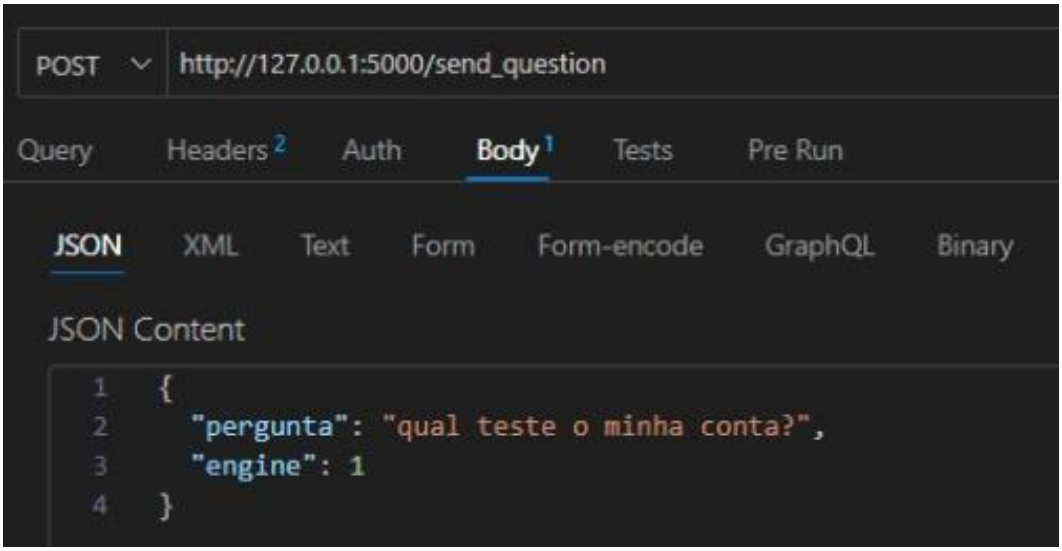

Fonte: De autoria própria.

Figura 6 – Exemplo utilizando o *Bert*

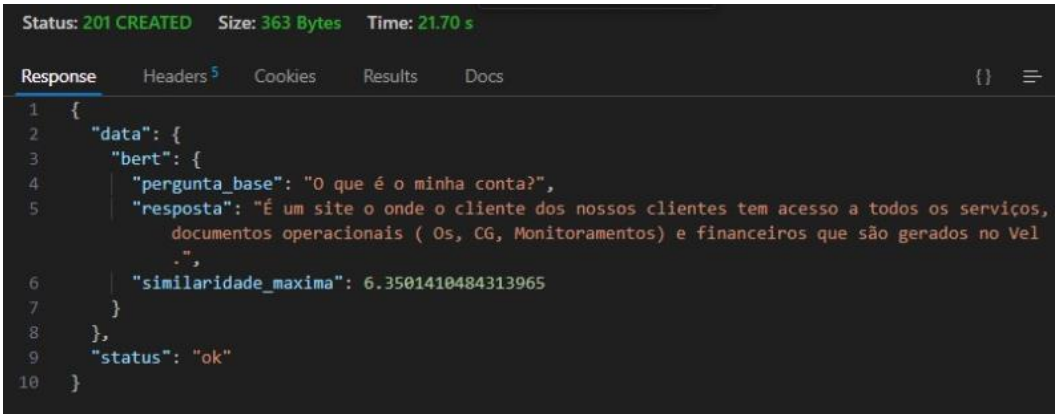

Fonte: De autoria própria.

Figura 7 – Exemplo utilizando o *Bert* (desempenho)

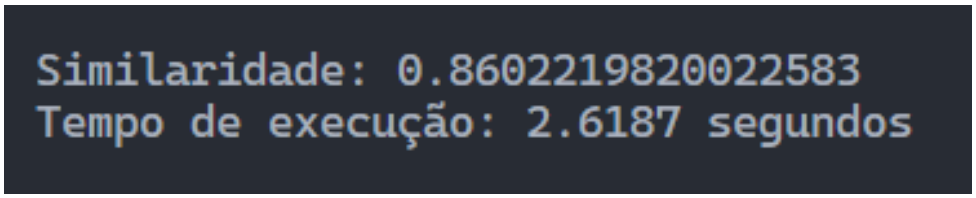

Fonte: De autoria própria.

Esse modelo, entre os outros, foi o que teve a maior assertividade comparando as seguintes frases: “*What do you like to do in the morning?*” e “*What do you enjoy*

doing in the beginning of the day?”, 86% de similaridade é algo aceitável, visto o modelo em questão, nem havia sido treinado para o propósito específico. Porém, o tempo de execução foi um pouco maior, e os testes de treinamento não foram tão bons, pois demorou um tempo considerável para finalizar, sendo algo escalável com a quantidade de comparações, esse modelo acabou não sendo a escolha final.

4.2.2. JACCARD

O coeficiente de *Jaccard* é uma medida estatística usada para calcular a similaridade entre dois conjuntos de dados. Ele é calculado dividindo o tamanho da interseção dos conjuntos pelo tamanho da sua união. Quanto mais próximo de 1 o valor do coeficiente de *Jaccard*, maior é a similaridade entre os conjuntos. Assim, o *Jaccard* não é exatamente um modelo de aprendizagem, e com isso, não é possível “aprender” de forma constante. Uma resposta que é dada como errada, mas é avaliada como certa, por exemplo, jamais poderá ser aprendida como correta, como nos modelos de aprendizagem. Apesar de o tempo de resposta ser baixo, já que não há nenhum processamento de texto, apenas comparação, o fato de não ser possível implementar a auto aprendizagem foi um ponto que inviabilizou o uso.

Figura 8 – Exemplo usando o Jaccard:

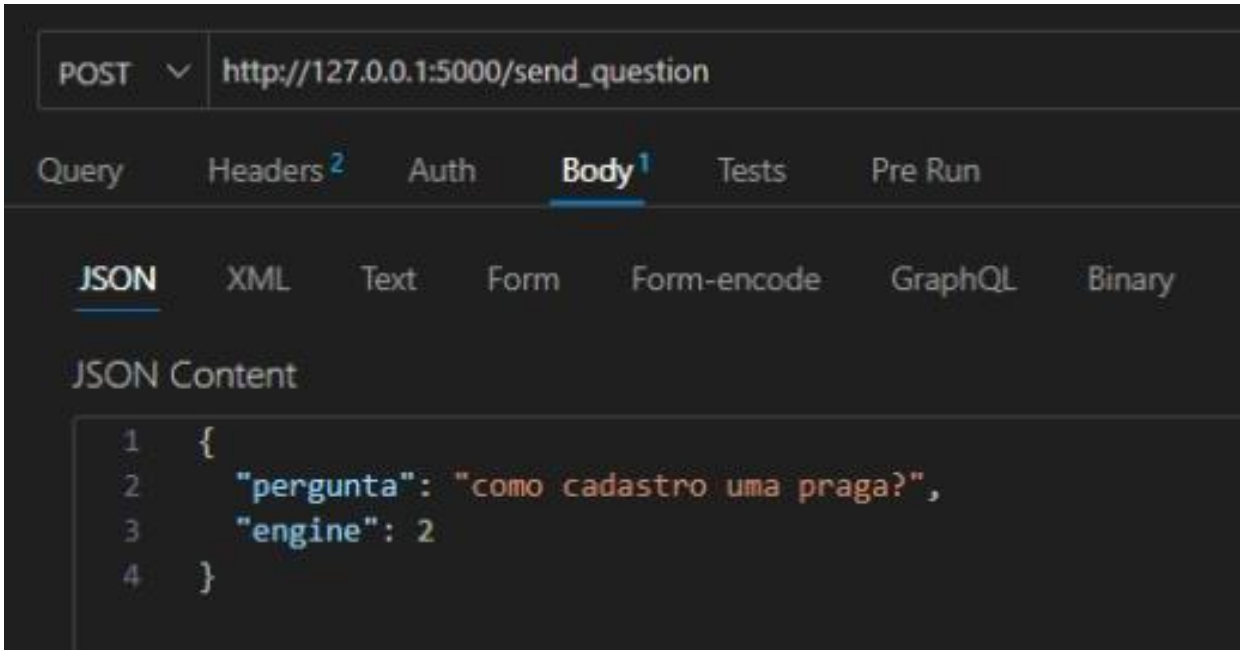

Fonte: De autoria própria.

Figura 9 – Exemplo utilizando o Jaccard

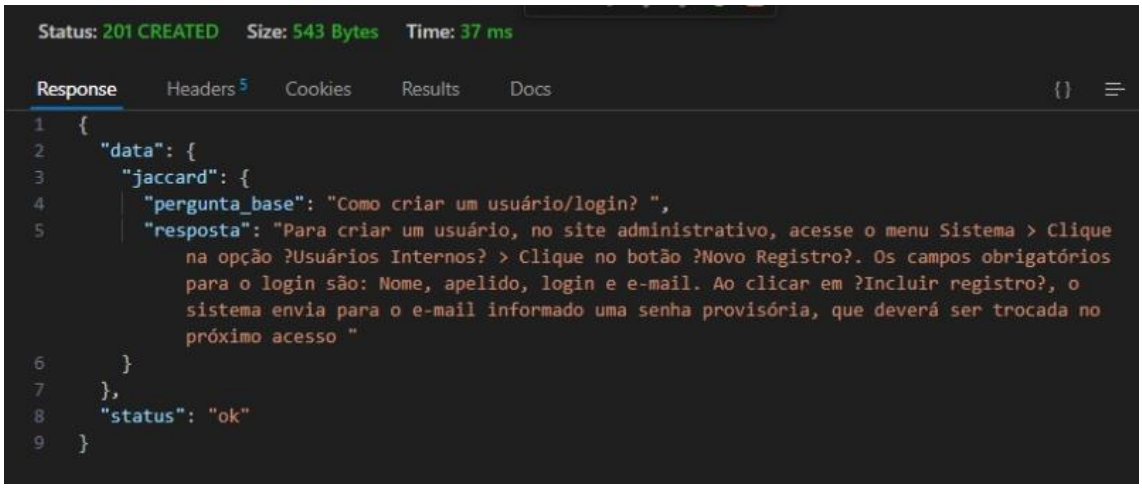

Fonte: De autoria própria.

Figura 10 – Exemplo usando o Jaccard (desempenho)

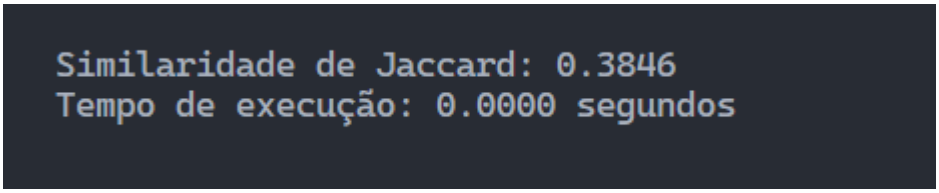

Fonte: De autoria própria.

Após realizar a comparação entre as frases: “*What do you like to do in the morning?*” e “*What do you enjoy doing in the beginning of the day?*”, observou-se que o tempo de execução apresentou um desempenho significativamente eficiente, sendo quase processado quase que instantaneamente. No entanto, a precisão dos resultados não se mostrou satisfatória, já que o resultado apresentou uma similaridade inferior a 40%. Este percentual de acerto demonstra a limitação do método utilizado, já que não há a possibilidade de um treinamento adicional para aprimoramento da taxa de assertividade, o que compromete sua capacidade de fornecer respostas mais assertivas em situações semelhantes.

Esse baixo índice evidencia a limitação do modelo utilizado, uma vez que não há a possibilidade de um treinamento adicional para aprimorar a taxa de acurácia, o

que compromete sua capacidade de fornecer respostas mais assertivas em situações semelhantes.

4.2.3. PARAPHRASE-MINILM

O *Paraphrase-MiniLM* é um modelo de linguagem baseado na arquitetura Transformer, projetado para tarefas de processamento de linguagem natural (NLP) como a geração de paráfrases, classificação de texto, e outras tarefas de entendimento de texto. Desenvolvido pela *Microsoft*, o *Paraphrase-MiniLM* foi feito para se tornar uma versão reduzida e otimizada da família de modelos *MiniLM* (*Mini Language Model*), que busca equilibrar a precisão e eficiência computacional, permitindo sua utilização em dispositivos com recursos limitados.

O funcionamento consiste basicamente em refazer as frases de formas diferentes das que foram ditas, exemplo: “Como faço para trocar minha senha?” teria uma taxa de similaridade alta com “Não estou conseguindo alterar minha senha.”, pois ambas as frases são paráfrases ou seja, formas diferentes de dizer a mesma coisa, daí o nome do modelo “*Paraphrase*”.

Assim como os outros, o seu idioma original é inglês, o que significa que ele se comporta melhor neste idioma por já ter sido modelado para esta finalidade. Contudo, isso não demonstra ser um empecilho, pois com alguns ajustes e treinamentos, ele consegue responder em outro idioma tão bem quanto no seu nativo.

Figura 11 – Trecho de código com implementação da IA

```python
from transformers import AutoTokenizer, AutoModel
import torch
import time
start_time = time.time()
# Carregar o tokenizer e o modelo Paraphrase-MiniLM
tokenizer = AutoTokenizer.from_pretrained('sentence-transformers/paraphrase-MiniLM-L6-v2')
model = AutoModel.from_pretrained('sentence-transformers/paraphrase-MiniLM-L6-v2')

# Frases de exemplo
sentences = ['What do you like to do in the morning?', "What do you enjoy doing in the beginning of the day?"]

# Tokenizar as frases e gerar embeddings
inputs = tokenizer(sentences, padding=True, truncation=True, return_tensors='pt')
with torch.no_grad():
    embeddings = model(**inputs).last_hidden_state.mean(dim=1)

# Calcular similaridade de cosseno entre as frases
cos_sim = torch.nn.functional.cosine_similarity(embeddings[0], embeddings[1], dim=0)

print('\n')
print(f'Similaridade: {cos_sim.item()}')
end_time = time.time()

# Calcula e imprime o tempo de execução
execution_time = end_time - start_time
print(f"Tempo de execução: {execution_time:.4f} segundos")
```

Fonte: De autoria própria.

Por fim, realizou-se um teste para avaliar tanto a velocidade de execução quanto a precisão do modelo em questão. Os resultados obtidos foram satisfatórios, considerando também o fato da facilidade na implementação, que exigiu poucas linhas de código para funcionar corretamente. Além disso, o tempo de execução apresentou-se como uma escolha acertada por conta da agilidade em processar as respostas, indicando que o modelo poderia ser uma escolha ideal para a tarefa proposta. Para validar o desempenho, foi utilizada a comparação entre as seguintes frases: "*What do you like to do in the morning?*" e "*What do you enjoy doing in the beginning of the day?*". O resultado desse teste pode ser visualizado na figura a seguir, a qual ilustra a similaridade calculada entre as frases e o tempo de resposta do modelo.

Figura 12 – Exemplo usando o Paraprhase (desempenho)

```
Similaridade: 0.7222047448158264
Tempo de execução: 2.1995 segundos
```

Fonte: De autoria própria.

Com base nos resultados apresentados, conclui-se que esse modelo atende de forma precisa às necessidades do sistema de atendimento proposto. Ele demonstra ser capaz de atender aos principais requisitos estabelecidos, que incluem a capacidade de fornecer respostas rápidas e funcionalmente adequadas em relação ao texto inserido pelo cliente final. A eficiência tanto na velocidade de processamento quanto na precisão das respostas torna-o uma escolha ideal para o contexto de interações automatizadas, contribuindo significativamente para a experiência do usuário e a eficiência operacional do sistema.

5. DIAGRAMA DE CASOS DE USO

Figura 13 – Diagrama de caso de uso

Fonte: De autoria própria.

Código	**Casuso – 01**
Título	**Solicitar atendimento**
Ator Principal	**Cliente**
Atores Secundários	**Suporte**
Descrição	**O cliente acessa o sistema para solicitar atendimento.**
Pré-condições	**O cliente precisa estar logado no sistema (ou se identificar), o sistema de atendimento precisa estar disponível.**
Pós-condições	**O cliente é direcionado para falar com a IA, ou se necessário, com o suporte humano. É iniciado o caso de uso Conversar.**
Fluxo Normal	
Ações do Ator	**Ações do Sistema**
Acessa a área de atendimento	
	Faz a triagem do cliente para o atendimento com a IA.
Restrições/Validações	**O sistema deve validar se o cliente está logado. O sistema deve verificar se o suporte está disponível.**
Observações	**A IA é utilizada para tratar consultas simples ou de baixo impacto, enquanto problemas mais complexos podem ser transferidos para o suporte humano.**
Fluxo Alternativo	
Ações do Ator	**Ações do Sistema**

Código	**Casuso – 02**
Título	**Fazer autenticação**
Ator Principal	**Cliente**
Atores Secundários	
Descrição	**Faz com que o cliente esteja identificado pra prosseguir com o atendimento.**
Pré-condições	**O cliente pode ou não estar identificado.**
Pós-condições	**O cliente precisa estar identificado.**
Fluxo Normal	
Ações do Ator	**Ações do Sistema**
Seleciona para ser atendido	
Envia as informações de identificação	
	Valida as informações e inicia o caso de uso conversar
Restrições/Validações	
Observações	**Caso o cliente já esteja identificado, não é necessário entrar com os dados para identificação.**
Ações do Ator	**Ações do Sistema**
Fluxo Alternativo 1	
	O cliente já está identificado.
	Segue para o caso de uso Conversar

Código	**Casuso – 03**
Título	**Conversar com a IA**
Ator Principal	**Cliente**
Atores Secundários	**IA**
Descrição	**O cliente fala com a IA para resolver um problema ou tirar dúvidas.**
Pré-condições	**O cliente deve ter se identificado, a IA deve estar operante e disponível.**
Pós-condições	**O cliente pode ter seu problema resolvido, ou o atendimento pode ser escalado para o suporte. A resposta da IA é avaliada.**
Fluxo Normal	
Ações do Ator	**Ações do Sistema**
Envia seu problema para a IA.	
	Interage com o cliente, coletando informações e fornecendo respostas.
Avalia o Atendimento	
Restrições/Validações	
Observações	**A IA pode ser usada para casos simples, como dúvidas frequentes.**
Ações do Ator	**Ações do Sistema**
Fluxo Alternativo 1	
Avalia o Atendimento	
	Se a IA não puder resolver o problema, o cliente solicita atendimento ao suporte (extensão).

Código	**Casuso – 04**
Título	**Conversar ao vivo por chat**
Ator Principal	**Cliente**
Atores Secundários	**Suporte**
Descrição	**O cliente fala diretamente com um atendente de suporte para resolver seu problema.**
Pré-condições	**O cliente deve ter solicitado atendimento. O suporte deve estar disponível. O cliente deve ter passado pelo atendimento da IA.**
Pós-condições	
Fluxo Normal	
Ações do Ator	**Ações do Sistema**
(Cliente) Envia sua dúvida para a suporte.	
	Encaminha a solicitação para os suportes disponíveis.
(Suporte) Coleta informações e oferece soluções.	
Restrições/Validações	**O sistema deve verificar a disponibilidade dos atendentes antes de redirecionar o cliente.**
Observações	
Ações do Ator	**Ações do Sistema**
Fluxo Alternativo 1	
	Não tem suporte disponível.
	Informa o cliente que o suporte não está disponível.

Código	**Casuso – 05**
Título	**Finalizar atendimento**
Ator Principal	**Cliente, Suporte**
Atores Secundários	
Descrição	**Se for finalizado pelo cliente, permite enviar transcrição por e-mail, já se for finalizado pelo suporte, permite gerar o ticket para acompanhamento posterior.**
Pré-condições	**O atendimento precisa estar em andamento.**
Pós-condições	**Se selecionada a opção pelo cliente , é enviada a transcrição ou se selecionada a opção pelo suporte é gerado o ticket.**
Fluxo Normal	
Ações do Ator	**Ações do Sistema**
Seleciona para finalizar o atendimento	
	Pergunta se deseja enviar. transcrição
Marca a opção e encerra.	
Restrições/Validações	**O cliente deve ter disponibilizado o e-mail na autenticação**
Observações	**Tanto o cliente quanto o suporte podem finalizar o atendimento.**
Ações do Ator	**Ações do Sistema**
É feito pelo suporte	
	Pergunta se deseja gerar um ticket para acompanhamento.
Marca a opção e encerra.	

Código	**Casuso – 06**
Título	**Enviar transcrição por e-mail**
Ator Principal	**Cliente**
Atores Secundários	
Descrição	**Faz o envio da transcrição, caso requerida pelo cliente.**
Pré-condições	**O atendimento precisa ser finalizado.**
Pós-condições	**É enviado um e-mail com a transcrição da conversa.**
Fluxo Normal	
Ações do Ator	**Ações do Sistema**
	Coloca toda a conversa no corpo do e-mail
	Faz o envio da transcrição por e-mail
Restrições/Validações	**O cliente deve ter disponibilizado o e-mail na autenticação**
Observações	
Ações do Ator	**Ações do Sistema**

Código	**Casuso – 07**
Título	**Gerar ticket para o atendimento**
Ator Principal	**Suporte**
Atores Secundários	
Descrição	**Permite a geração do ticket para acompanhamento posterior.**
Pré-condições	**O atendimento precisa estar em andamento.**
Pós-condições	**É gerado o ticket para o atendimento.**
Fluxo Normal	
Ações do Ator	**Ações do Sistema**
	Gera ticket para o atendimento
	Anexa a conversa no ticket
Restrições/Validações	
Observações	
Ações do Ator	**Ações do Sistema**

Código	**Casuso – 08**
Título	**Treinar Inteligência Artificial**
Ator Principal	**Relógio**
Atores Secundários	
Descrição	**Faz o treinamento da IA de tempos em tempos.**
Pré-condições	**O tempo foi pré definido, o sistema está operante.**
Pós-condições	**O treinamento fica armazenado.**
Fluxo Normal	
Ações do Ator	**Ações do Sistema**
Manda a requisição para o servidor executar o treinamento	
	Executa o treinamento
Restrições/Validações	**É necessário ter espaço em disco.**
Observações	
Ações do Ator	**Ações do Sistema**

Código	**Casuso – 09**
Título	**Validar treinamento**
Ator Principal	**Suporte**
Atores Secundários	
Descrição	**Permite que o suporte valide o treinamento do modelo para fazer o aprimoramento do mesmo.**
Pré-condições	**Deve haver um treinamento para ser validado**
Pós-condições	**A IA passa a utilizar o treinamento validado.**
Fluxo Normal	
Ações do Ator	**Ações do Sistema**
Analisa o feedback das perguntas pré setadas no novo modelo treinado.	
Da o ok para o novo modelo ser utilizado.	
	Troca o modelo para o novo.
Restrições/Validações	
Observações	
Ações do Ator	**Ações do Sistema**
Fluxo Alternativo 1	
O suporte rejeita o novo modelo treinado.	
	O novo modelo é deletado.

Código	**Casuso – 10**
Título	**Fazer login**
Ator Principal	**Suporte**
Atores Secundários	
Descrição	**Faz a validação do suporte**
Pré-condições	
Pós-condições	**O Suporte fica autenticado no sistema.**
Fluxo Normal	
Ações do Ator	**Ações do Sistema**
Informa login e senha	
	Valida as informações
	Prossegue pra tela inicial
Restrições/Validações	
Observações	**Caso o cliente já esteja identificado, não é necessário entrar com os dados para identificação.**
Ações do Ator	**Ações do Sistema**
Fluxo Alternativo 1	
	Login e/ou senha incorretos
	Solicita novo preenchimento

6. DIAGRAMA DE CLASSES

Figura 14 – Diagrama de classe

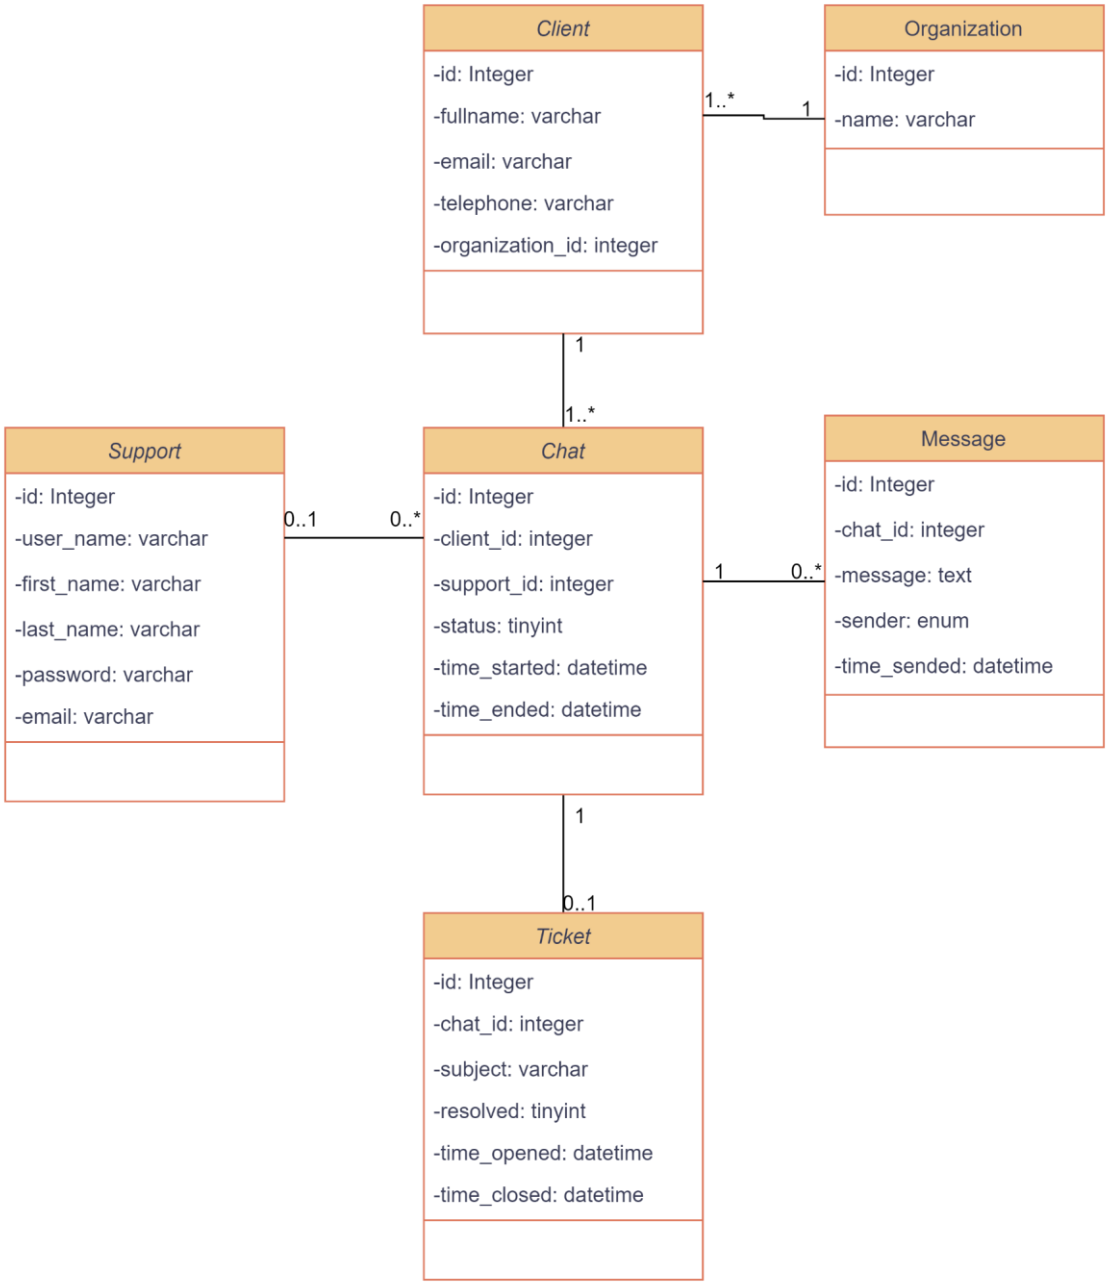

Fonte: De autoria própria.

7. DICIONÁRIO DE DADOS

Figura 15 – Dicionário de dados - *Chat*

Tabela	Chat			
Descrição	Armazena as informações das conversas			
Observações	Tabela principal que faz ligação com quase todas as outras			
Nome	Descrição	Tipo de dado	Tamanho	Restrições de domínio (PK, FK, Not Null, Check, Default, Identity)
id	Chave primária de identificação	Int	11	PK / Identity
client_id	Chave estrangeira referenciando ao cliente da conversa	Int	11	FK
support_id	Chave estrangeira referenciando ao suporte da conversa	Int	11	FK
status	Status atual da conversa	Tinyint	4	Default "0"
time_started	Momento de inicio do chat	Datetime		Null
time_ended	Momento de finalização do chat	Datetime		Null

Fonte: De autoria própria.

Figura 16 – Dicionário de dados - Cliente

Tabela	Client			
Descrição	Armazena as informações dos clientes que iniciam os atendimentos			
Observações				
Nome	Descrição	Tipo de dado	Tamanho	Restrições de domínio (PK, FK, Not Null, Check, Default, Identity)
id	Chave primária de identificação	Int	11	PK / Identity
fullname	Nome do cliente	Varchar	255	Null
email	E-mail do cliente, também utilizado para autenticação	Varchar	255	Unique / Not Null
telephone	telefone do cliente	Varchar	255	Null
organization_id	Chave estrangeira referenciando a organização do cliente	Int	11	Not Null

Fonte: De autoria própria.

Figura 17 – Dicionário de dados - Organiza

Tabela	Organization			
Descrição	Tabela cujo objetivo é o agrupamento de clientes por organização			
Observações				
Nome	'	Tipo de dado	Tamanho	Restrições de domínio (PK, FK, Not Null, Check, Default, Identity)
id	Chave primária de identificação	Int	11	PK / Identity
name	Nome da organização	Varchar	255	Not Null

Fonte: De autoria própria.

Figura 18 – Dicionário de dados - Suporte

Tabela	Support			
Descrição	Armazena informações de autenticação do suporte			
Observações				
Nome	Descrição	Tipo de dado	Tamanho	Restrições de domínio (PK, FK, Not Null, Check, Default, Identity)
id	Chave primária de identificação	Int	11	PK / Identity
username	String de acesso do suporte a plataforma de atendimento	Varchar	255	Null
firstname	Primeiro nome do suporte	Varchar	255	Not Null
lastname	Sobrenome ou ultimo nome do suporte	Varchar	255	Not Null
password	Senha de acesso do suporte a plataforma de atendimento	Varchar	255	Not Null
email	E-mail do suporte	Varchar	255	Unique / Not Null

Fonte: De autoria própria.

Figura 19 – Dicionário de dados - *Ticket*

Tabela	Ticket			
Descrição	Armazena informações de autenticação do suporte			
Observações				
Nome	Descrição	Tipo de dado	Tamanho	Restrições de domínio (PK, FK, Not Null, Check, Default, Identity)
id	Chave primária de identificação	Int	11	PK / Identity
chat_id	Conversa vinculada ao ticket	int	11	Not Null
subject	Assunto do ticket	Varchar	255	Null
resolved	Status do ticket (0 = Aberto, 1 = Resolvido)	Tinyint	1	Default "0"
time_opened	Momento de abertura do ticket	Datetime		Null
time_closed	Momento de finalização do ticket	Datetime		Null

Fonte: De autoria própria.

8. DIAGRAMA ARQUITETURAL

Figura 20 – Diagrama arquitetural

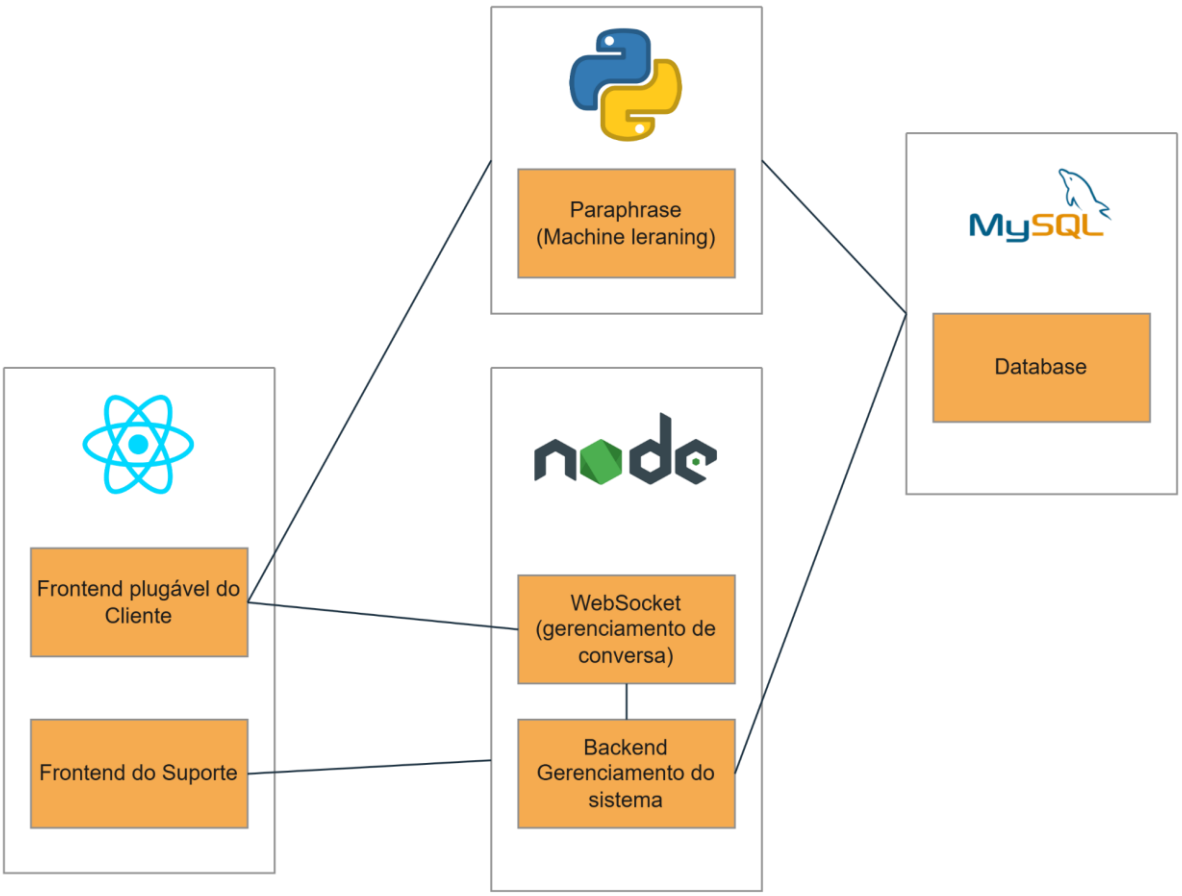

Fonte: De autoria própria.

9. FLUXO DE TELAS

9.1. MODAL FECHADO

A imagem abaixo representa a exibição do botão do modal enquanto estiver fechado,

Figura 21 - Botão de acesso ao modal do cliente

Fonte: De autoria própria.

9.2. FORMULÁRIO DE IDENTIFICAÇÃO

Formulário de identificação inicial do cliente, requerido caso o atendimento seja para um cliente não logado. Caso contrário, os dados de login do sistema serão suficientes.

Figura 22 - Tela de identificação do cliente

Fonte: De autoria própria.

9.3. MENSAGEM INICIAL DO CHAT

Figura 23 - Tela de mensagem de boas-vindas

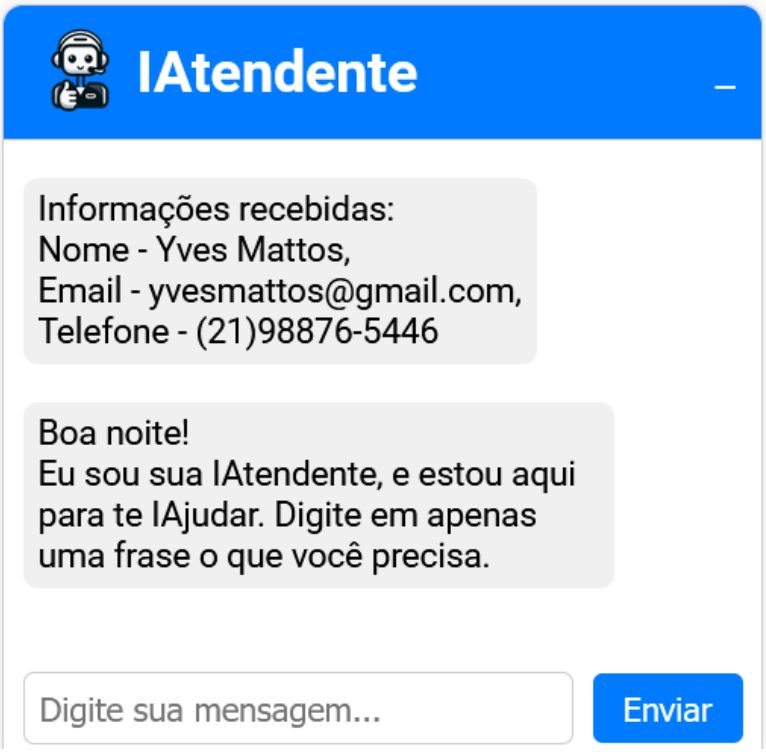

Fonte: De autoria própria.

9.4. MENSAGEM ENVIADA PELO CLIENTE

A imagem abaixo apresenta a resposta da IA após o cliente ter perguntado o que é uma remessa. A resposta é exibida e então o cliente pode marcar a resposta como suficiente ou se será necessário um atendimento humanizado.

Figura 24 - Tela de conversação com a IA

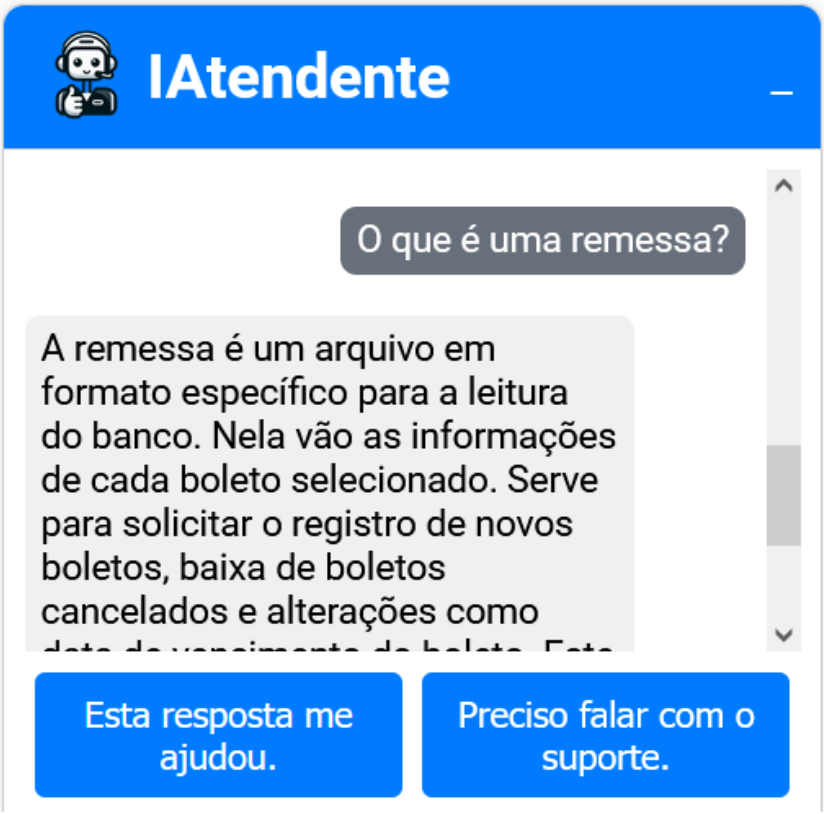

Fonte: De autoria própria.

9.5. LOGIN DO SUPORTE

Figura 25 - Tela de identificação do suporte

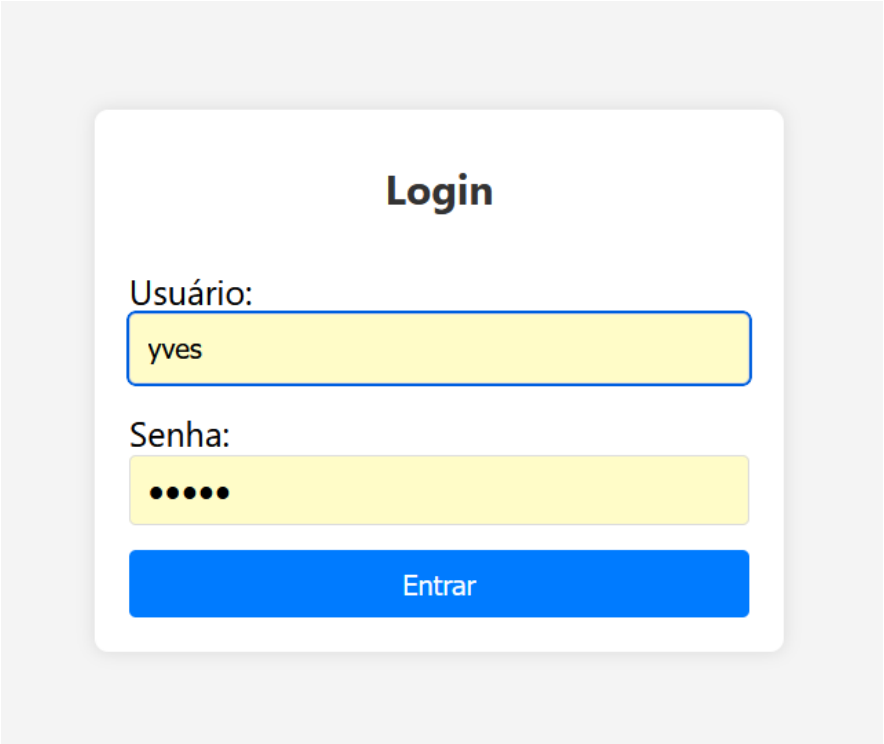

Fonte: De autoria própria.

9.6. TELA INICIAL DO SISTEMA DO SUPORTE

Após o login, o suporte é direcionado para a tela principal do sistema, onde consegue visualizar os chats pelo qual é responsável ou os chats que ainda não tenham nenhum suporte atribuído, isto é, os chats pendentes.

Figura 26 - Tela inicial do suporte autenticado

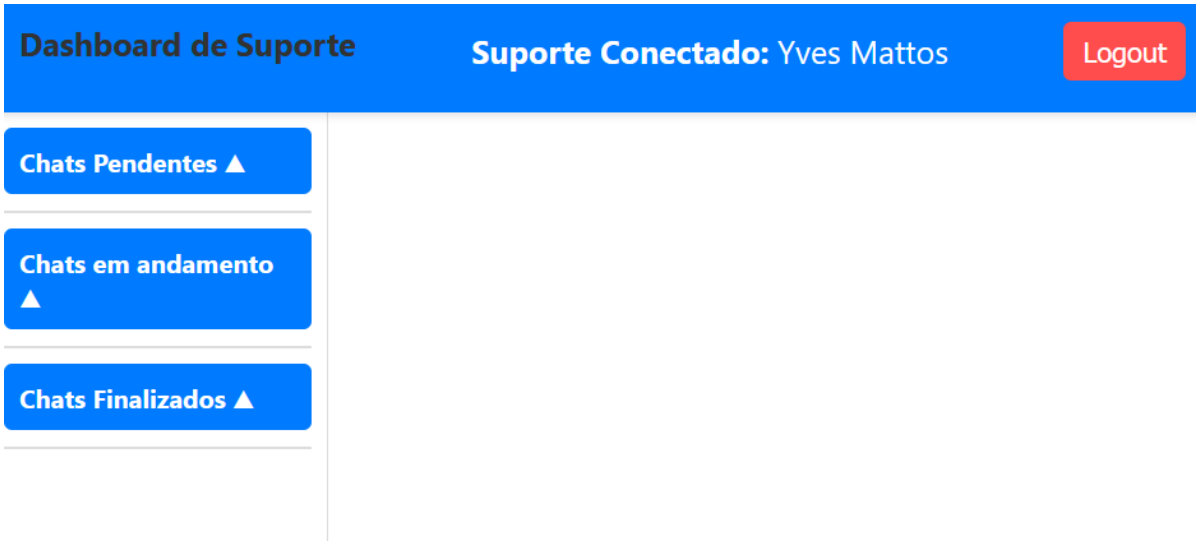

Fonte: De autoria própria.

9.7. INTERAÇÃO ENTRE CLIENTE E SUPORTE

Após sinalizar que a resposta da IA não foi suficiente, o cliente envia a mensagem para um suporte humano. A mensagem vai para uma lista de espera de todos os suportes. Qualquer suporte pode visualizar os chats pendentes e se tornar o atendente responsável por ele. Porém, após um suporte ser atribuído ao chat, somente ele poderá visualizar e responder as mensagens.

Figura 27 - Tela de início da conversa do cliente com o suporte

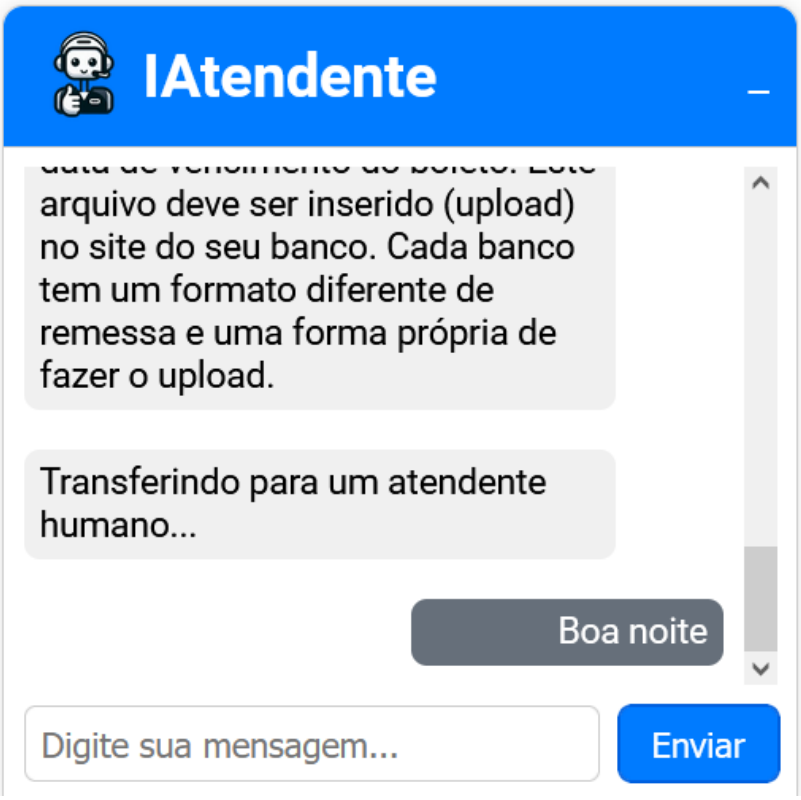

Fonte: De autoria própria.

9.8. NOTIFICAÇÃO DE ATENDIMENTO NA TELA DO SUPORTE

Quando é enviada uma mensagem pela parte do cliente, todos os suportes ativos conseguem ver a notificação, e posteriormente selecionar essa notificação para adquirir o chamado de atendimento para si.

Figura 28 - Notificação da mensagem do cliente para o suporte

Fonte: De autoria própria.

9.9. CONVERSA COM O CLIENTE

O suporte consegue nessa tela realizar a troca de mensagens com o cliente, assim como também consegue marcar o atendimento como resolvido.

Figura 29 - Resposta do suporte ao cliente

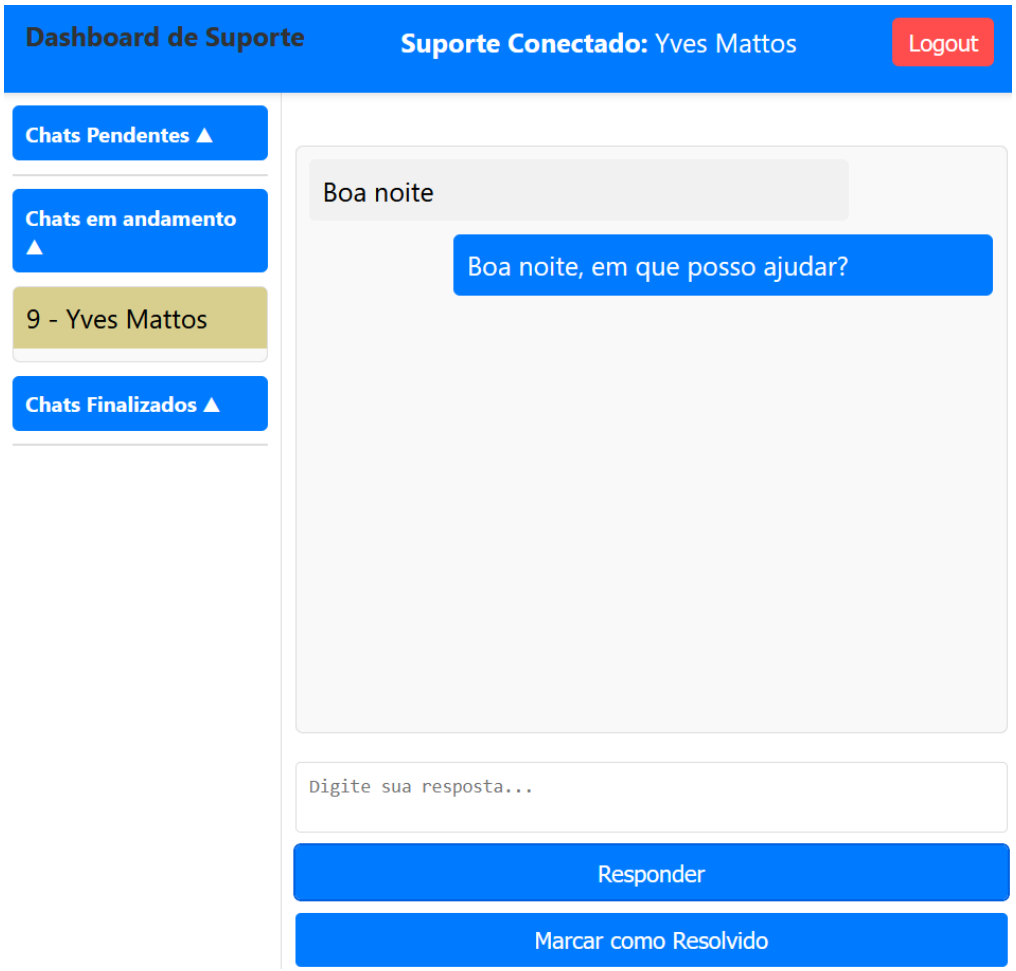

Fonte: De autoria própria.

Figura 30 - Exibição da mensagem do suporte ao cliente vista da parte do cliente

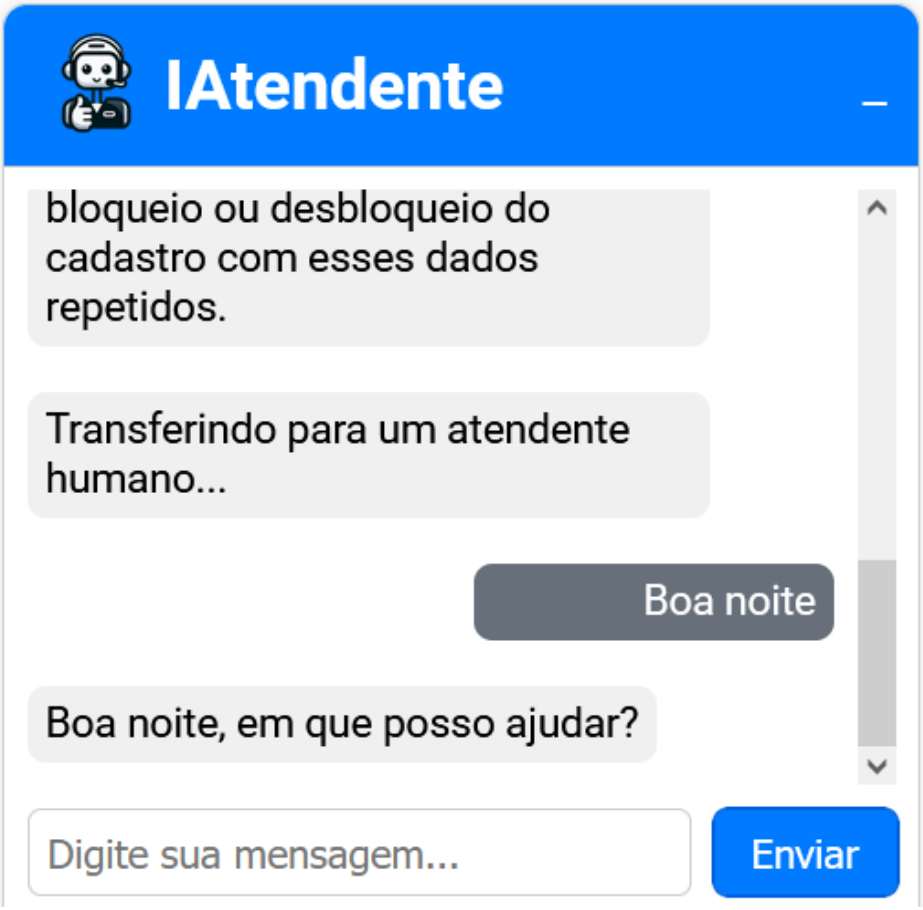

Fonte: De autoria própria.

9.10. ABERTURA DE TICKET

Após o chat ser encerrado, ele fica disponível na aba de chat finalizado para a abertura de ticket, o ticket permite o acompanhamento posterior desse problema que não foi resolvido no chat.

Figura 31 - Abertura de ticket

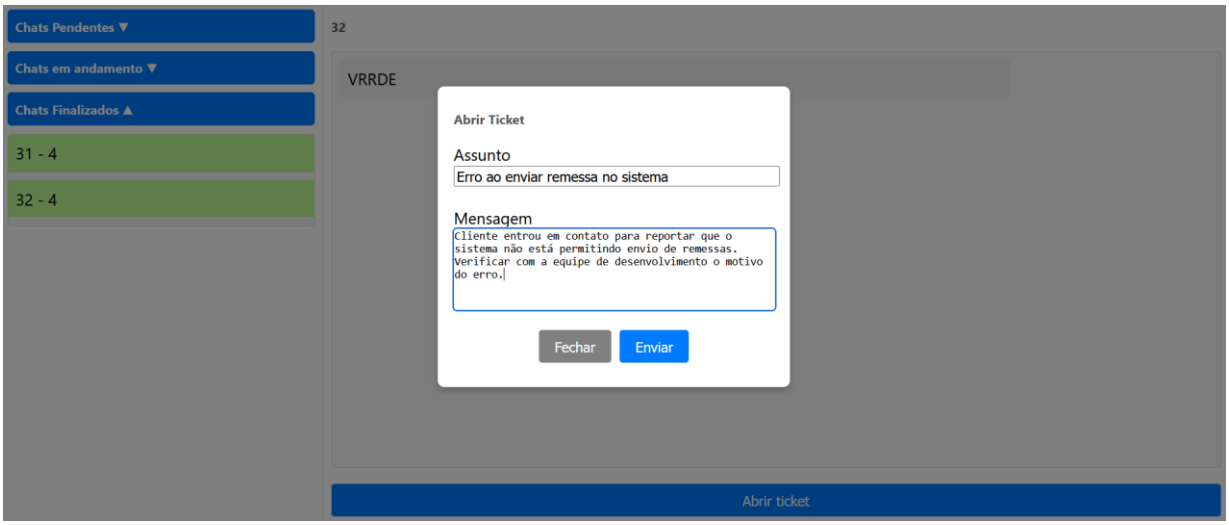

Fonte: De autoria própria.

10. CONCLUSÃO

11. CONSIDERAÇÕES FINAIS

Conforme apresentado, a implementação de uma ferramenta de chat integrada com inteligência artificial representa um avanço significativo na qualidade e na eficiência do atendimento. Essa integração permite a redução de demandas repetitivas, proporcionando agilidade e precisão no atendimento de solicitações críticas, ao mesmo tempo que mantém um caráter humanizado no suporte em tempo real. Ademais, com a utilização de uma IA dotada de capacidade de aprendizado contínuo, o sistema demonstra um potencial constante de evolução, contribuindo para a melhoria progressiva dos processos e para a satisfação dos usuários finais.

12. ENCAMINHAMENTOS FUTUROS

Para garantir a melhoria contínua do sistema e aumentar sua capacidade de atendimento, recomenda-se implementar algumas funcionalidades que, embora não sejam essenciais para o MVP, são importantes para a evolução do projeto. Entre elas, destaca-se a automatização do aprendizado dos modelos de IA, que tornará o sistema mais adaptável e eficiente ao longo do tempo. Além disso, funcionalidades como acompanhamento de tickets e envio de e-mails com cópias das conversas podem melhorar o gerenciamento do atendimento, oferecendo mais organização e melhor experiência para os usuários.

13. REFERÊNCIAS

VERSIANI, Rafael. ***Como o suporte técnico pode agregar valor à sua empresa?*** eNotas, 2023. Disponível em: https://enotas.com.br/blog/suporte-tecnico. Acesso em: 3 out. 2024. [1]

HUGGING FACE. Disponível em: https://huggingface.co/. Acesso em: 3 out. 2024. [2]

RDSTATION. ***Machine Learning: o que é, para que serve, como funciona e como aplicá-lo ao Marketing Digital.*** Disponível em: https://www.rdstation.com/blog/marketing/machine-learning/. Acesso em: 3 out. 2024.

ZENDESK. ***Tipos de atendimento ao cliente: principais abordagens, técnicas e tendências.*** Disponível em: https://www.zendesk.com.br/blog/tipos-de-atendimento-ao-cliente/. Acesso em: 22 jul. 2024. [3]

PPNTECNOLOGIA. ***Como a Inteligência Artificial pode impulsionar o desempenho do seu negócio.*** Disponível em: https://ppntecnologia.com.br/atendimento-ao-cliente/seguranca-e-produtividade-como-a-inteligencia-artificial-pode-impulsionar-o-desempenho-do-seu-negocio/ . Acesso em: 12 nov. 2024.

AGENDOR. ***Ferramentas de atendimento: 4 sistemas indispensáveis para a operação.*** Disponível em: https://www.agendor.com.br/blog/ferramentas-de-atendimento/ . Acesso em: 12 nov. 2024.

Programmers; **10 heurísticas de Nielsen: Melhorando a usabilidade de suas interfaces**; Disponível em: https://www.programmers.com.br/blog/10-heuristicas-de-nielsen-melhorando-a-usabilidade/. Acesso em: 25/11/2023

Digital House; **UX x UI: qual a diferença e como as áreas se completam;** Disponível em: https://www.digitalhouse.com/br/blog/diferenca-entre-ux-e-ui/. Acesso em: 25/11/2023

BUCKHOUT, S.; FREY, E.; NEMEC JR., J. Por um ERP eficaz. HSM Management p. 30-36, set./out. 1999. Disponível em: https://www.scielo.br/j/gp/a/GmLSKVc7dpRYdBhtbChHDcv/?format=pdf. Acesso em: 20 abr. 2024

TOMTICKET. Disponível em: <https://www.tomticket.com/>. Acesso em: 17 abr. 2024.

Schunk, L. M. ***O uso de inteligência artificial por meio de chatbots no processo de atendimento ao cliente: Um estudo sobre seus benefícios*****.** São Paulo, 2020. Disponível em: https://repositorio.fgv.br/server/api/core/bitstreams/12b8022f-e8eb-4628-8c4d-e641e7c716b3/content. Acesso em: 23/08/2024.